

PONTIFÍCIA UNIVERSIDADE CATÓLICA DO RIO DE JANEIRO

# **Métodos Preditivos de Longo Prazo para Fontes de Energia Intermitentes**

Uma análise em cima da eficiência atual do NEWAVE em  
proposta de melhoria

**Gustavo Maia Riedel**

**PROJETO FINAL DE GRADUAÇÃO**

**CENTRO TÉCNICO CIENTÍFICO – CTC  
DEPARTAMENTO DE INFORMÁTICA**

**Curso de Graduação em Engenharia da Computação**

novembro de 2025



Gustavo Maia Riedel

# **Métodos Preditivos de Longo Prazo para Fontes de Energia Intermitentes**

Uma análise em cima da eficiência  
atual do NEWAVE em proposta de  
melhoria

Relatório de Projeto Final, apresentado ao programa de  
Graduação do DEPARTAMENTO DE INFORMÁTICA da  
PUC-Rio como requisito parcial para a obtenção do título  
de Engenheiro de Computação.

**Orientadora:** Paula Maçaira

**Coorientador:** Augusto Cesar Espíndola Baffa

Rio de Janeiro  
novembro de 2025

*"Alis grave nil"*  
*Lema da PUC-Rio*

## Agradecimentos

Dedicamos este trabalho aos nossos orientadores pelo estímulo, direcionamento e parceria fundamentais para a realização deste trabalho.

Agradecemos também as agências de fomento CAPES, CNPq, FAPERJ e à PUC-Rio, pelos auxílios concedidos, sem os quais este trabalho não poderia ter sido realizado.

Aos nossos familiares por todo suporte, atenção e carinho incondicionais, que sempre me motivaram e apoiaram em cada etapa desta trajetória.

Aos nossos colegas da PUC-Rio, pelo companheirismo, pelo apoio mútuo e pelas inúmeras trocas de conhecimento que enriqueceram esta jornada.

A todos os professores e funcionários do Departamento de informática, pelos ensinamentos, pela dedicação e pela disposição em ajudar sempre que necessário.

A todos os amigos e familiares que, de uma forma ou de outra, estiveram presentes, oferecendo palavras de incentivo, suporte e compreensão ao longo dessa caminhada.

Nossos sinceros agradecimentos a todos que continuamente contribuem, direta ou indiretamente, para a concretização deste trabalho. trabalho.

## Resumo

O resumo deve apresentar objetivo, método, resultados e conclusões em sequência de frases, sem fórmulas ou citações. Escreva de forma clara e direta, destacando a contribuição do trabalho e o recorte do problema abordado.

**Palavras-chave:** escreva; até; cinco; termos; aqui.

## Abstract

A concise summary in English stating objective, method, main results and conclusions (preferably up to 250 words), without formulas or references.

**Keywords:** write; up to five; terms; here.

## Lista de Figuras

1	Arquitetura Atual do SEB. . . . .	2
2	Mapa da Hidrografia Brasileira. . . . .	3
3	Matriz Elétrica Brasileira. . . . .	4
4	Tomada de Decisão para Geração de Energia Hidrelétrica . . . . .	5
5	Previsto pelo Deck 2024 vs Real . . . . .	16
6	Diferença entre Real e Previsto . . . . .	17
7	Diferença Média Entre Previsões . . . . .	18
8	Real contra Previsto Deck Newave 2023 . . . . .	19
9	Média das Previsões contra Real . . . . .	20
10	Deck de FEV/2021 contra Real . . . . .	20
11	Parte 1 Cronograma . . . . .	22
12	Parte 2 Cronograma . . . . .	22
13	Parte 3 Cronograma . . . . .	22

## **Lista de Tabelas**

1	Exemplo da Disposição de Dados Para Análise do NEWAVE . . . . .	15
2	Métricas Calculadas Para Geração Eólica do NEWAVE . . . . .	16

# Sumário

## Lista de Figuras

## Lista de Tabelas

<b>1</b>	<b>Introdução</b>	<b>1</b>
<b>2</b>	<b>Estrutura do Setor Elétrico</b>	<b>2</b>
2.1	Fontes de Energia Intermitentes . . . . .	4
2.2	Algoritmos de Previsão Atualmente Utilizados . . . . .	6
2.2.1	NEWAVE . . . . .	6
2.3	Proposta de Solução . . . . .	7
<b>3</b>	<b>Objetivos</b>	<b>8</b>
3.1	Definição dos Modelos . . . . .	10
3.1.1	Camada Convolucional . . . . .	10
3.1.2	Camada LSTM . . . . .	11
3.1.3	Camada Informer . . . . .	11
3.1.4	XGBoost . . . . .	11
3.2	Arquitetura Integrada Proposta . . . . .	12
<b>4</b>	<b>Revisão do Plano de Ação</b>	<b>13</b>
4.1	Plano de Ação do Treinamento do Modelo . . . . .	14
4.2	Apresentação de Resultados do NEWAVE . . . . .	15
4.3	Limitações Previstas . . . . .	21
<b>5</b>	<b>Cronograma</b>	<b>22</b>
<b>6</b>	<b>Bibliografia</b>	<b>23</b>



# 1 Introdução

A previsão é uma das ferramentas mais importantes do setor de energia, sendo responsável por tornar possível a compreensão de métricas muito longe do nosso alcance. Uma usina de geração de energia em escala industrial, dura anos para ser confeccionada, nesse sentido, é vital que se perceba sua necessidade anos antes dela ser de fato sentida.<sup>1</sup>

Nesse sentido, previsões incorretas, falta de acurácia ou confiabilidade nas previsões geradas por um algoritmo podem ser desastrosas e acabar guiando de maneira errônea anos de concentração de esforços e recursos.

Tendo isso em mente, o setor elétrico brasileiro desenvolveu diversas métricas e algoritmos para conseguir compreender o consumo e a geração de energia anos à frente, para que seja possível planejar e desenvolver qualquer contra medida, dado o cenário previsto.<sup>2</sup>

Além da previsão de consumo, nosso setor elétrico também desenvolve previsões visando geração. Qual a previsão de incidência solar da semana que vem? Quanto teremos nos reservatórios de água em 6 meses? Até mesmo, quanto conseguiremos gerar com energia eólica em 5 anos? Todas essas são perguntas que o SEB se esforça para responder, auxiliado por potentes algoritmos.<sup>3</sup>

Contudo, devido ao avanço recente de integração de fontes de energias renováveis e de geração menos constante à nossa rede, esses algoritmos podem vir se tornando menos confiáveis e menos apropriados para previsão de geração de energia intermitente.<sup>4</sup>

Esse trabalho terá como objetivo, portanto, checar a capacidade do modelo atualmente utilizado para previsões de longo prazo em relação à geração de energia eólica no nordeste brasileiro. Além disso, também se propõe a gerar um modelo mais coeso e que se mantenha mais próximo dos valores reais registrados, sendo capaz de captar e reagir às mudanças de geração de modo mais ágil.

---

<sup>1</sup>Castro e Matsumura (2021).

<sup>2</sup>Oliveira (2020).

<sup>3</sup>Centro de Pesquisas de Energia Elétrica (CEPEL) (2023).

<sup>4</sup>WIND/PV... (2024) e THE... (2023).

## 2 Estrutura do Setor Elétrico

Para compreender os algoritmos utilizados pelo setor elétrico, é necessário entender sua estrutura. A imagem 1 explicita bem o funcionamento atual do setor elétrico brasileiro (SEB) do ponto de vista burocrático.



Figura 1: Arquitetura Atual do SEB.

Fonte: Autoria Própria

A responsável pela formulação de novas diretrizes, políticas, assessoramento à Presidência da República e assegurar que insumos energéticos assolam todas as áreas do país é o Conselho Nacional de Política Energética (CNPE). Esse conselho vigia todas as outras instituições responsáveis por tarefas mais específicas. O Ministério de Minas e Energias (MME), conduz as políticas energéticas do país e supervisiona, tanto a Empresa de Pesquisa Energética (EPE), responsável por conduzir pesquisas focadas no desenvolvimento do setor, quanto, o Comitê de Monitoramento do Setor Elétrico (CMSE), responsável por acompanhar e assegurar a continuidade e disponibilidade do suprimento energético.

Ainda sob supervisão do MME, possuímos a Agência Nacional de Energia Elétrica (ANEEL), responsável por regular e fiscalizar a produção, transmissão, distribuição e comercialização de energia elétrica. Além disso a ANEEL também chefia, tanto o Operador Nacional do Sistema Elétrico (ONS), responsável por operar a rede elétrica, quanto a Câmara de Comercialização de Energia Elétrica (CCEE), sendo essa responsável pela viabilização de compra e venda de energia por todo o território<sup>5</sup>.

<sup>5</sup>(CONHEÇA. . . , 2025). Acesso em: 04 nov. 2025.

Como pode ter ficado claro, o setor elétrico brasileiro conta com grande organização e planejamento. Para que se simplifique a divisão, geração e distribuição de energia, o Brasil foi dividido em 4 grandes subsistemas, Sudeste/Centro-Oeste, Sul, Nordeste e Norte. Essa divisão se dá por diversos motivos, dentre eles, a interligação do nosso sistema hídrico, como se percebe na figura 2, os rios brasileiros são muito interligados, dado nossa matriz energética altamente dependente de hidrelétricas, uma usina no norte que feche sua comporta, poderá causar seca em usinas no sudeste, por exemplo. Além disso, essa subdivisão permite uma visão macro do nosso sistema interligado nacional, o sistema de distribuição energética criado em 1998 para permitir que o Brasil funcione como uma grande rede elétrica, no lugar de funcionar como diversas usinas separadas e não coordenadas.<sup>6</sup>

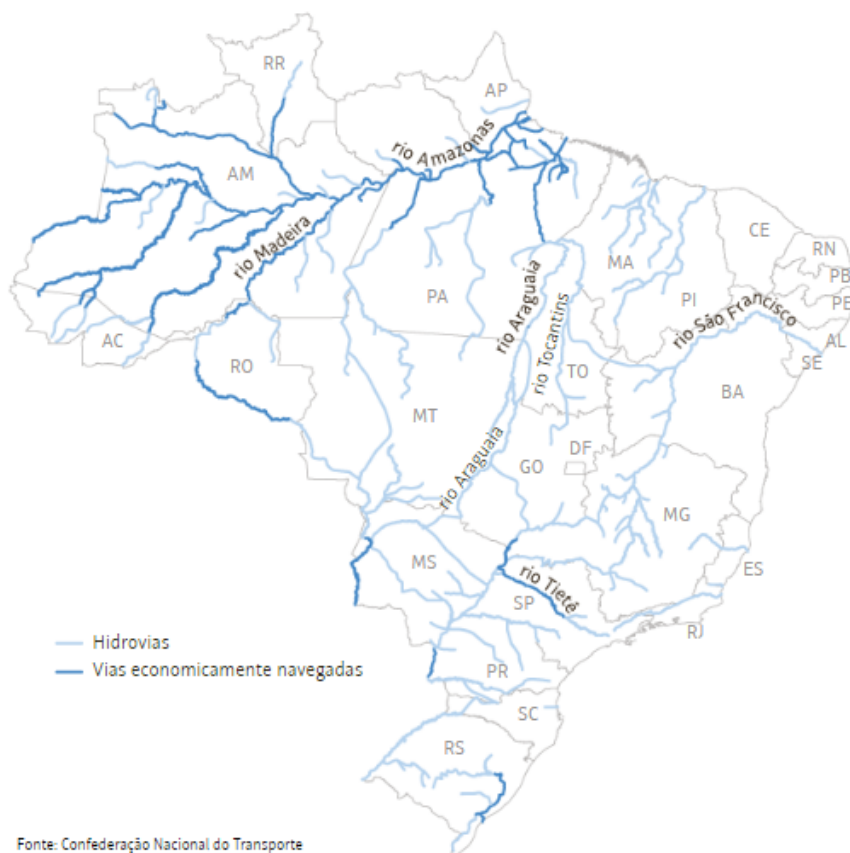


Figura 2: Mapa da Hidrografia Brasileira.  
 Fonte: (MAPA. . . , 2019)

Desse modo é possível que uma geração extra de energia em Santa Catarina, devido à por exemplo alto índice pluviométrico recente, ajude a cobrir um período de seca e baixa dos reservatórios de usinas hidrelétricas em Pernambuco.<sup>7</sup>

<sup>6</sup>Oliveira (2020).

<sup>7</sup>(Brasil. Operador Nacional do Sistema Elétrico (ONS), 2025). Acesso em: 04 nov. 2025.

## 2.1 Fontes de Energia Intermitentes

Nossa matriz elétrica é baseada em energia hidráulica, ou seja, transformamos a energia potencial gravitacional da água em energia elétrica. A ideia é simples, aproveitar o fluxo de água gerado por um rio para produzir energia elétrica. Atualmente nós utilizamos de dois tipos de usinas hidrelétricas, as chamadas de fio d'água, que não possuem reservatório, e as com reservatório. Essa é considerada uma fonte de energia renovável, pois se aproveita do círculo natural da água, que mantém os rios fluindo e a correnteza mantém energia sendo gerada.<sup>8</sup>




Figura 3: Matriz Elétrica Brasileira.  
Fonte: (Brasil. Empresa de Pesquisa Energética (EPE), 2025)

Como é possível observar na figura 3, a energia hidráulica possui um papel protagonista em nossa matriz, contudo, outras formas de geração como eólica e solar, ainda entram no pódio e possuem suas particularidades.

Nesse estudo, a principal diferença explorada entre a geração de energia eólica/solar e a hidráulica é a intermitência. Usinas hidrelétricas com reservatório permitem que a energia seja produzida à demanda, afinal, podemos armazenar a água com alto potencial gravitacional no reservatório e gerar energia quando necessário até que o armazenamento se esvazie<sup>9</sup>. Fontes intermitentes, referidas neste estudo e no cenário brasileiro principalmente como eólica e solar, não podem ser armazenadas e são aproveitadas ao máximo quando em geração. No SEB sempre temos que tomar a decisão

<sup>8</sup>Empresa de Pesquisa Energética (EPE) (2007).

<sup>9</sup>Brandão *et al.* (2024).

entre produzir com energia hidrelétrica ou utilizar outra forma a fim de poupar o reservatório, essas decisões são tomadas a partir da previsão do nível do reservatório.<sup>10</sup> Essa dualidade que o operador enfrenta na tomada de decisão pode ser ilustrada pela figura 4

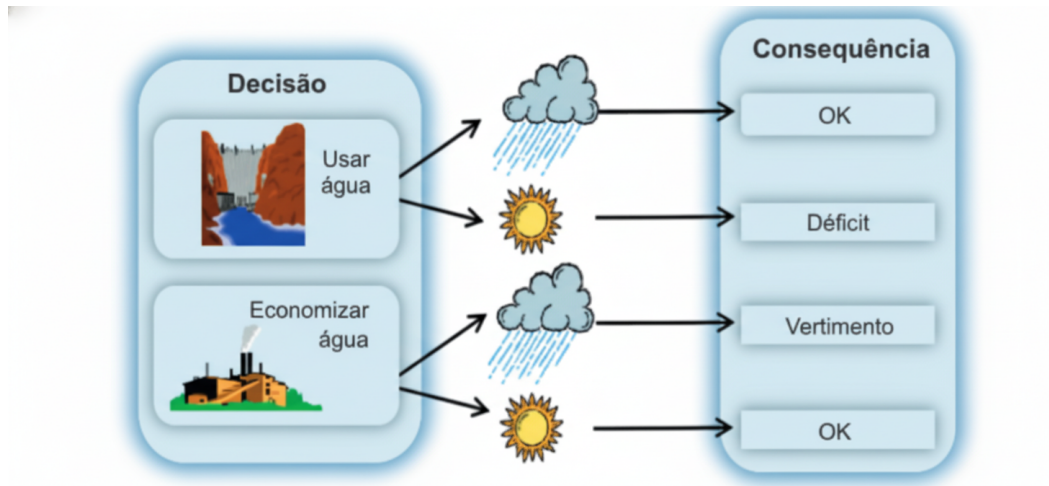


Figura 4: Tomada de Decisão para Geração de Energia Hidrelétrica  
Fonte: (Oliveira, 2020)

Antes da introdução de fontes intermitentes essa decisão era feita entre geração de energia por meio de combustão, que era cara, contudo podia ser gerada de modo muito rápido indefinidamente. (Agência Nacional de Energia Elétrica (ANEEL), 2022)

Hoje em dia, esse cenário se inverteu, utilizamos fontes intermitentes quando possível, e hidrelétrica como segunda opção.<sup>11</sup> As usinas de combustão continuam produzindo em casos de emergenciais de falta de reservatório à um alto custo. Contudo, fontes intermitentes não são capazes de agir como usinas a combustão. Fontes eólicas precisam vencer a inércia para começar a produção e ainda sofrem uma variação enquanto produzem. Usinas solares não sofrem com inércia e começam a geração instantaneamente, contudo, são ainda mais intermitentes, haja visto que uma nuvem pode cortar a produção pela metade ou até por completo de modo repentino. Além disso, ambas dependem de fatores externos que não podem ser controlados para gerar energia.<sup>12</sup>

Nesse contexto, torna-se imprescindível um modo de compreender a geração de energia intermitente como um método barato, mas arriscado de geração energética. No cenário atual, para energia eólica, mantemos uma reserva chamada R eólico, um percentual que deve ser gerado acima do disponível a fim de combater a intermitência. No Sudeste que possui ventos mais constantes esse R é de 6%, já no Sul, que possui

<sup>10</sup>Neto *et al.* (2023).

<sup>11</sup>THE... (2023).

<sup>12</sup>WIND/PV... (2024).

ventos de rajada, esse R é de 15%, ou seja, 15% da produção deve ser reservada com o único objetivo de combater a intermitência e permitir que, em caso de cessão de ventos, tenhamos tempo de iniciar uma produção de outra fonte a tempo. Vale ressaltar também que falta de ventos não é o único fator que pode impedir a geração de energia eólica. Aerogeradores contam com velocidades de máxima e de mínimo, conhecidas na indústria como cut-in e cut-out, que explicitam um range no qual aquele aerogerador estará apto a funcionar e produzir energia.<sup>13</sup>.

## **2.2 Algoritmos de Previsão Atualmente Utilizados**

Três modelos são utilizados para previsão de geração de energia, DECOMP, DESSEM e NEWAVE. Eles se diferenciam principalmente pelo horizonte de previsão que tentam abranger.

DESSEM é o modelo do CEPEL para o curtíssimo prazo (diário e até cerca de duas semanas), com discretização de até meia hora, que determina a programação detalhada da operação hidrotérmica e a integração de fontes intermitentes. Sua formulação captura com alto nível de detalhe as restrições do problema (como função de produção das usinas, limites de rede e aspectos não lineares), apoiando o ONS no despacho operacional diário e em análises de sensibilidade quando há condições operativas desafiadoras. O resultado é um cronograma horário de geração e intercâmbios que concilia segurança elétrica e eficiência econômica.<sup>14</sup>.

DECOMP é o modelo do CEPEL voltado ao curto prazo (semana/mês) para sistemas hidrotérmicos, utilizado oficialmente pelo ONS na elaboração do Programa Mensal da Operação (PMO) e pela CCEE. Ele refina, em maior detalhe, as políticas obtidas no planejamento de longo prazo, resolvendo um problema estocástico com representação de restrições operativas (hidráulicas, térmicas e de rede) e calculando custos marginais de operação coerentes com as condições hidrológicas e de demanda. Assim, o DECOMP entrega estratégias semanais de despacho e intercâmbio entre subsistemas, respeitando limites físicos e energéticos do SIN. Vale ressaltar, que esse, assim como os outros algoritmos, é focado para o setor hidroenergético.<sup>15</sup>

### **2.2.1 NEWAVE**

NEWAVE é um modelo computacional avançado desenvolvido pelo CEPEL para o planejamento da operação de sistemas geradores de energia de longo prazo. Ele visa suportar decisões estratégicas e operacionais do SIN, determinando políticas de operação que focam em minimizar o custo total da produção, composto pelo custo imediato e futuro.

---

<sup>13</sup>Oliveira (2020).

<sup>14</sup>Operador Nacional do Sistema Elétrico (ONS) (2002).

<sup>15</sup>Centro de Pesquisas de Energia Elétrica (CEPEL) (2023).

O modelo utiliza de uma técnica conhecida como Programação Dinâmica Dual Estocástica, para enfrentar a natureza caótica presente em fontes de energia renováveis como eólica, hídrica e solar. Esse método permite que o algoritmo calcule, para cada subsistema (Norte, Nordeste, Sul, Sudeste-CentroOeste), uma função de custo futuro, cuja derivada resulta no valor da água. Essa abordagem possibilita obter despacho das usinas hidroelétricas, termoeletricas e outras usinas chamadas de “não simuladas” como usinas aerogeradores, solar e dentre outras.<sup>16</sup>

Para que o NEWAVE funcione corretamente, ele depende de um conjunto de dados organizados em arquivos padronizados. Dentre eles estão:

- Informações Gerais e de Configuração: Dados dos sistemas e subsistemas ou submercados, além do cadastro das usinas (hidrelétrica, termelétrica, eólica...).
- Séries Históricas e Tendências Hidrológicas: Dados de vazão históricas, postos fluviométricos e arquivos de tendência, dados históricos dos parques eólicos, incluindo medição de velocidade e direção do vento, curvas de produção.
- Dados Operacionais e de Restrição Informações dos custos de combustível, restrições de intercâmbio de energia, parâmetros de manutenção.<sup>17</sup>

Como saída, o algoritmo gera relatórios que incluem não apenas os valores previstos de geração energética para um horizonte de 60 meses, mas também, indicadores de desempenho, como custos marginais e valores associados à energia. Esses são conhecidos como “valor da água”, mas já foram adaptados para refletir o comportamento de outras fontes intermitentes. Esses resultados são fundamentais para o planejamento estratégico, afinal, permitem que os operadores ajustem a oferta e a integração das fontes renováveis de forma dinâmica. Como é possível notar, o NEWAVE é um algoritmo com foco em previsão de energia com base em afluentes, designado para geração de energia hidrelétrica, mesmo que tenha sido adaptado recentemente para prever também geração de energia eólica, solar, microgeradores independentes e dentre outros. Essa atualização não indica muito desenvolvimento dito que métodos estocásticos ainda se encontram na categoria de não simulados, ou seja, sua média de geração é considerada, ao invés de uma previsão apropriada.<sup>18</sup>

## 2.3 Proposta de Solução

Com essa estrutura do NEWAVE em mente e, considerando as particularidades da geração de energia eólica, é válido se indagar se a acurácia ou precisão desse modelo é de fato alta e se podemos considerá-lo uma ferramenta confiável. Esse trabalho por tanto irá se comprometer em estudar os resultados do NEWAVE e entender se é necessária a criação de um novo modelo capaz de trazer resultados mais relevantes e

<sup>16</sup>Centro de Pesquisas de Energia Elétrica (CEPEL).

<sup>17</sup>Operador Nacional do Sistema Elétrico (ONS) (2002).

<sup>18</sup>Centro de Pesquisas de Energia Elétrica (CEPEL) (2023).

confiáveis do que a alternativa atual. Além disso, esse trabalho também se propõe, em caso de confiabilidade insatisfatória por parte do NEWAVE, em desenvolver um modelo que seja mais capaz de retornar previsões de alta confiança para o mesmo horizonte de tempo.

Para avaliar essa acurácia, foi conduzida uma análise aprofundada comparando as previsões de geração eólica do NEWAVE (desde abril de 2020) com os dados reais registrados pelo Operador Nacional do Sistema Elétrico (ONS), focando no subsistema Nordeste.

A metodologia de análise baseou-se na coleta e tratamento de dois conjuntos de dados principais: os dados históricos reais de geração eólica, obtidos diretamente do Operador Nacional do Sistema Elétrico (ONS), e os dados de previsão gerados pelos "decks" do modelo NEWAVE. Os dados do ONS foram estruturados cronologicamente, detalhando a geração por subsistema, com foco principal no subsistema Nordeste, dada a sua relevância na geração eólica nacional. Paralelamente, os dados do NEWAVE foram extraídos de múltiplos decks de previsão mensais, cada um contendo projeções de geração para os cinco anos subsequentes. Esses decks foram coletados diretamente do site do CCEE em seu acervo online.<sup>19</sup>

Após esse processo de extração de dados dos decks e dos dados reais do ONS, tudo seria disposto em uma planilha e várias métricas seriam traçadas a partir do valor real e do valor de previsão. Como por exemplo, comparação entre decks específicos e os dados reais, média das previsões e real, erro da média das previsões, erro de um deck específico e assim por diante.

Para isso seriam utilizadas ferramentas como Google Planilhas para registro dos dados e cálculos de algumas métricas, assim como plotagem de gráficos. o Google Colab também se entendeu como uma ferramenta vital, não só para plotagem de gráficos e cálculo de métricas de erro, como também para a extração de dados dos decks. Ambos os ambientes estarão disponíveis no anexo deste relatório. Para a segunda etapa deste estudo, focaremos mais no Google Colab e em ferramentas de geração de inteligência artificial, como scikit-learn para acesso à modelos neurais de qualidade.

### 3 Objetivos

O atual estudo apresenta como principal objetivo, destacar fraquezas no atual modelo de previsão de geração de energia à longo prazo, e, baseado nessas fraquezas, se comprometer a desenvolver um modelo utilizando métodos mais atuais de previsão e redes neurais mais completas e robustas para o complexo desafio de previsão com horizonte de 60 meses.

---

<sup>19</sup>CCEE (2025).



A nossa atual solução, NEWAVE, é desenvolvida de modo determinístico e é baseada em dados médios históricos, ou seja, representa de modo muito pobre a real possibilidade de geração. Para geração de energia eólica, o elemento aleatório é vital para uma previsão apropriada, e considerar apenas as médias históricas sem levar em consideração outros fatores que levam aquela geração específica, como temperatura, umidade e diversos outros fatores enfraquece a previsão.<sup>20</sup>

Com isso em mente e, visando a crescente na integração de fontes de energia intermitentes à nossa rede e ao SIN, torna-se imprescindível a implementação de um modelo capaz de prever com boa precisão a geração de energia em todos os horizontes. No caso específico do NEWAVE e previsão ao longo prazo, precisamos ter em mente a capacidade de geração de energia e quanto será gerado para que possamos compreender a necessidade de confecção de novas usinas. Um parque eólico pode demorar até uma década para ser construído e é necessário que seu planejamento e construção comece muito antes que sua necessidade seja sentida.<sup>21</sup>

Espera-se conquistar uma confiabilidade maior, erro e erro quadrático menor do que os níveis atuais do NEWAVE entregam, além disso a capacidade de previsão acurada em apenas um deck também deverá ser melhor, ou seja, considerando um modelo treinado com dados até 2021 ele precisará prever os próximos 5 anos de modo mais acurado do que o NEWAVE no mesmo período.

Portanto o presente documento irá abordar as seguintes etapas. Primeiro a coleta de dados para o entendimento da efetividade do atual modelo de previsão. Os dados serão coletados no site oficial do Operador Nacional do Sistema Elétrico. Além disso, iremos coletar os decks das previsões do NEWAVE, especificamente os decks de abril de 2020 até janeiro de 2025 contendo as previsões para os próximos 5 anos. Iremos comparar essas previsões com o que de fato ocorreu. Após isso, iremos gerar um modelo e rodar o mesmo teste que fizemos para o NEWAVE nele, vendo assim se conseguimos gerar um modelo com maior confiança.

Para a geração do modelo, iremos coletar os dados do ERA5, usando sua API. Além disso também serão coletadas informações específicas sobre os parques eólicos atualmente instalados em território brasileiro. Desse modo saberemos as coordenadas as quais devemos focar nos dados do ERA5. Assim, baixamos um quadrante e traçamos os pontos para cada aerogerador. Com os dados prontos e tratados, eles serão imputados em dois modelos neurais, um ensemble e um outro modelo sozinho de teste.

---

<sup>20</sup>PRIORIZAÇÃO... (2022).

<sup>21</sup>Castro e Matsumura (2021).

### 3.1 Definição dos Modelos

O ponto de partida desta pesquisa é pragmático: na prática operacional que motivou este trabalho, observamos que o NEWAVE possui altos indícios de que não se comporta bem como previsor de longo prazo para fontes intermitentes. O modelo foi concebido para otimização hidrotérmica em horizontes de médio/longo prazo e, embora cumpra esse papel, não captura adequadamente padrões finos, mudanças de regime e não linearidades típicas de vento e irradiação. Em contrapartida, a literatura especializada recente em previsão de energia mostra ganhos consistentes quando se adotam modelos de aprendizado, em especial ensembles, que combinam vieses complementares e reduzem a variância do erro em horizontes maiores. É exatamente a estratégia que propomos aqui.<sup>22</sup>

Essa estratégia central seria um modelo que combina dois previsores de natureza distinta, um recorrente (LSTM) e um atencional (Informer). Alimentados por um extrator convolucional de atributos, além de um modelo de controle não neural (XGBoost) que não estaria junto dos outros modelos e serviria como uma comparação no resultado final. A justificativa estatística é clássica: algoritmos diferentes erram de maneiras diferentes, ao agregá-los, parte do erro idiossincrático se cancela e a robustez aumenta. Essa intuição é coerente com resultados do estudo aplicado de Belotti (2019) em previsão hidrológica, no qual ensembles baseados em redes neurais superaram configurações individuais, especialmente em horizontes mais longos e sob maior ruído.<sup>23</sup>

Além disso, duas frentes da literatura reforçam a escolha dos blocos do ensemble: (i) redes recorrentes ainda são bases sólidas para séries de vento/energia (inclusive em horizontes longos) e podem ser otimizadas para melhores rampas e estabilidade; (ii) arquiteturas com atenção (como o Informer) capturam dependências de longo alcance com custo computacional controlado; e (iii) extratores convolucionais (CNN) produzem representações locais/hierárquicas mais informativas para os previsores temporais subsequentes. Desse modo o modelo fica robusto aos principais desafios enfrentados por esse tipo de problema, quantidade de features, quantidade de dados sendo utilizados para uma mesma previsão e horizonte dessa previsão. Também justificamos o XGBoost como modelo de controle por seu desempenho consistente em previsão eólica de longo prazo com dados amostrados em diferentes intervalos.<sup>24</sup>

#### 3.1.1 Camada Convolucional

O primeiro estágio do pipeline aprende filtros convolucionais 1D sobre as séries (potência, vento, variáveis meteorológicas, índices sazonais etc.), gerando mapas de atributos que destacam transições, frequências locais e motivos recorrentes. A vantagem é dupla, comprimir ruído enquanto realça padrões relevantes e facilitar o trabalho do

<sup>22</sup>Centro de Pesquisas de Energia Elétrica (CEPEL) (2023).

<sup>23</sup>Belotti (2019).

<sup>24</sup>Barbounis *et al.* (2006); e Ahmadi *et al.* (2020).

previsor temporal ao entregar uma representação já estruturada. O estudo modelo CNN–ResNet50–LSTM detalha exatamente esse papel. Pilhas de convoluções com ReLU, pooling para redução dimensional, blocos residuais (ResNet50) para aprendizagem profunda estável, e então a passagem para uma LSTM capturar a dinâmica temporal.<sup>25</sup>

### 3.1.2 Camada LSTM

A Long Short-Term Memory (LSTM) introduz um estado de célula e portas consistindo de entrada, esquecimento e saída. Essas portas modulam o fluxo de informação, mitigando o vanishing gradient. Em vento/energia, as LSTMs permanecem competitivas para horizontes longos, especialmente quando alimentadas por atributos bem construídos. Possuimos evidência histórica de RNNs locais de longo prazo para vento<sup>26</sup> e estudos recentes que otimizam LSTMs com meta-heurísticas modernas, reforçando o papel da arquitetura como base robusta para previsão eólica. Esse modelo de rede neural é muito comum em aplicações de previsão eólica pois se dão muito bem com bases que remetem, ou sejam, séries temporais.<sup>27</sup>

### 3.1.3 Camada Informer

O Informer é uma variação de Transformer focada em previsão de longo alcance com atenção esparsa e camadas de distilling no codificador. A estrutura encoder–decoder permanece, mas a atenção multi-cabeças é direcionada a tokens mais informativos, reduzindo a complexidade e melhorando a escalabilidade sem perder a capacidade de capturar dependências globais. O estudo LSTM–Informer com Ensemble Learning ilustra a combinação: uma camada LSTM inferior ajuda a preservar correlações de curto prazo enquanto o Informer aprende relações de longo prazo via atenção. Foi relatado ganhos em horizontes maiores justamente por essa divisão de papéis. O Informer entra como um especialista capaz de escolher e prestar mais atenção à dados que irão enriquecer a previsão, acaba sendo nosso especialista de longuíssimo prazo.<sup>28</sup>

### 3.1.4 XGBoost

Como baseline/controlado, empregamos XGBoost (gradient boosting de árvores), que lida bem com não linearidades e interações sem exigir extensa normalização/engenharia. No estudo analisado de previsão eólica de longo prazo, os autores comparam algoritmos “tree-based” e mostram que o XGBoost alcançou a melhor acurácia em horizonte de seis meses à frente, superando outras alternativas e evidenciando ainda a sensibilidade ao intervalo de amostragem, quanto maior a resolução temporal, menor a perda de representatividade e queda de desempenho.<sup>29</sup>

<sup>25</sup> Elshewey, Jamjoom e Alkhamash (2025).

<sup>26</sup> Barbounis *et al.* (2006).

<sup>27</sup> Ewees *et al.* (2022).

<sup>28</sup> Wang *et al.* (2023).

<sup>29</sup> Ahmadi *et al.* (2020).

### 3.2 Arquitetura Integrada Proposta

A arquitetura proposta organiza-se como um pipeline hierárquico que transforma sinais brutos em previsões de horizonte longo por meio de estágios com funções bem definidas. Inicialmente, realiza-se um pré-processamento temporal que inclui normalizações adequadas, construção de janelas deslizantes e engenharia de variáveis de calendário e defasagens, além da integração de potenciais exógenas (por exemplo, variáveis meteorológicas de reanálise ou de modelos numéricos). Essa etapa é crítica porque reduz heterogeneidades e fornece ao modelo pistas explícitas sobre periodicidades e atrasos relevantes à geração eólica. Em seguida, aplica-se um extrator convolucional 1D (CNN), cujo papel é aprender filtros locais que realçam motivos, transições e frequências de interesse, entregando mapas de atributos mais informativos e compactos para os previsores temporais. Evidências empíricas reportadas na literatura indicam que essa estratégia de aprender atributos hierárquicos antes de modelar a dinâmica temporal, melhora a estabilidade do treinamento e a acurácia em cenários climáticos não lineares<sup>30</sup>.

A partir desses mapas, a arquitetura ramifica-se em dois ramos complementares. O primeiro ramo emprega uma LSTM, que modela dependências sequenciais por meio de estados de célula e portas, mantendo memória de longo prazo e mitigando o problema de gradientes evanescentes. Assim, captura com eficácia correlações locais e sazonais características da potência eólica. O segundo ramo utiliza um Informer, uma variante de Transformer projetada para horizontes ultra longos com mecanismos de atenção esparsa e camadas de distilling no codificador, o que reduz a complexidade e permite focalizar relações globais no tempo. Quando combinados, esses ramos distribuem o trabalho de modelagem: a LSTM acompanha a evolução de curto a médio prazo, enquanto o Informer captura padrões de maior escala com custo computacional controlado<sup>31</sup>. As saídas desses dois ramos são então fundidas por uma regra de ensemble simples (média ponderada, com pesos ajustados por validação) ou por stacking com um meta-regressor raso, o que tende a reduzir a variância do erro e a tornar a previsão mais robusta a quebras de regime. Um racional consistente com resultados clássicos de ensembles em séries hidrológicas<sup>32</sup>.

Em paralelo, treina-se um modelo de controle não neural (XGBoost) com o mesmo alvo e conjunto de atributos (ou um subconjunto engenheirado). Além de servir como baseline quantitativo, o XGBoost oferece interpretabilidade por importância de variáveis e conduz a análises de sensibilidade úteis para verificar a coerência das entradas com o conhecimento físico do problema. Em estudos comparáveis de previsão eólica de longo prazo, o XGBoost frequentemente apresenta competitividade elevada e evidencia ainda o impacto do intervalo de amostragem nos erros agregados, o que orienta escolhas de

<sup>30</sup> Elshewey, Jamjoom e Alkhamash (2025).

<sup>31</sup> Wang *et al.* (2023).

<sup>32</sup> Belotti (2019).

granularidade na construção do conjunto de dados<sup>33</sup>. Em síntese, a arquitetura acopla:

- extração convolucional para limpar e enriquecer representações;
- modelagem recorrente para dinâmicas locais;
- atenção eficiente para dependências de longo alcance;
- baseline tree-based para controle metodológico e interpretabilidade.

## 4 Revisão do Plano de Ação

O trabalho constituiu-se de uma investigação sistemática sobre a eficácia do modelo NEWAVE, a ferramenta oficial do SIN, especificamente na sua capacidade de prever a geração de energia eólica. O objetivo central foi quantificar a acurácia deste modelo, que foi originalmente projetado para sistemas hidrelétricos e posteriormente adaptado para fontes intermitentes.

O primeiro passo concreto foi a coleta e estruturação de dados. Foram adquiridos dois conjuntos de dados distintos: primeiro, os dados históricos reais de geração eólica, obtidos diretamente do Operador Nacional do Sistema Elétrico (ONS), com foco no subsistema Nordeste devido à sua alta representatividade. Segundo, foram extraídas as previsões de geração eólica de múltiplos "decks" mensais do NEWAVE, compilando um histórico de projeções desde abril de 2020. Nesse sentido foi gerado um notebook python para ajudar na extração dos dados do deck que são muito mal estruturados, e colocá-los na planilha para facilitar a comparação posterior. A planilha foi também transformada em um csv ao final da imputação dos dados, para que um programa em python pudesse calcular métricas mais complexas como variação inter-deck de previsão, ou seja, o quanto uma mesma previsão varia de um deck para outro.

Foi realizado também, um tratamento para organizar esses dados de forma que as previsões de diferentes decks para uma mesma data pudessem ser diretamente comparadas com os valores reais registrados pelo ONS.

Com os dados estruturados, a execução da análise foi dividida em etapas. Primeiramente, foi feita uma análise da performance de decks de previsão individuais. Isso envolveu plotar graficamente as projeções de decks específicos contra a série histórica real. Foi analisado um deck de longo prazo (fevereiro de 2021), onde se constatou uma falha completa em prever o crescimento do setor, resultando em subestimações drásticas. Em seguida, foi analisado um deck de curto prazo (janeiro de 2024), que demonstrou um comportamento caótico e um erro médio elevado, cerca de 1600 MWmed, mesmo para previsões dentro do próprio ano.

---

<sup>33</sup>Ahmadi *et al.* (2020).

Diante da baixa aderência individual, foi formulada e testada a hipótese de que o modelo poderia ser "exato na média". Para isso, foi calculado o valor médio de todas as previsões disponíveis (oriundas de todos os decks coletados) para cada data futura. Esta curva de média foi então plotada contra os dados reais, e o que se fez foi confirmar a hipótese: a média das previsões de fato converge e apresenta uma aderência muito superior à realidade. Adicionalmente, foi calculado o desvio padrão dessas múltiplas previsões ao longo do tempo, observando-se que as previsões tendem a convergir à medida que a data prevista se aproxima.

Portanto, o que foi feito, em suma, foi demonstrar quantitativamente a ineficiência dos decks individuais do NEWAVE para geração eólica e, ao mesmo tempo, revelar a característica contraintuitiva de que a média de suas previsões é precisa. Com base nestas análises, foi comprovado que o modelo é inadequado para esta finalidade, por ser uma ferramenta adaptada que não captura a sazonalidade nem o crescimento do setor. Além disso, ficar dependente da média não é um cenário ideal, afinal continua comprovando a ineficiência do modelo no longo prazo, que seria seu principal objetivo. Se fizermos a média das previsões de jan/2021 até jan/2025 para obtermos um resultado razoável para previsão de fev/2025 o modelo falhou seu propósito.

#### **4.1 Plano de Ação do Treinamento do Modelo**

Avaliamos os modelos respeitando a ordem do tempo. Em vez de misturar amostras antigas e novas aleatoriamente, usamos rolling origin, pegamos um bloco antigo para treinar e um bloco mais recente para validar; depois “andamos” a janela para frente e repetimos. Isso evita vazamento de informação do futuro para o passado e mostra se o modelo se mantém estável em climas diferentes.

Nos modelos neurais, usamos early stopping: durante o treinamento, acompanhamos o erro no conjunto de validação e paramos quando o erro deixa de melhorar por algumas épocas, evitando que o modelo decore o conjunto de treino. Aplicamos também dropout moderado nas camadas densas ou recorrentes para reduzir overfitting. No Informer, preferimos configurações que não cresçam demais: ajustamos a profundidade do codificador, o número de cabeças de atenção e o nível de “distilling” por busca orientada, justamente para manter um bom equilíbrio entre capacidade e generalização.

Para o XGBoost, os principais botões são: número de árvores, profundidade máxima, taxa de aprendizado e as frações de amostragem por linha e por coluna. Ajustamos isso por grid search ou random search, sempre usando a mesma validação temporal que usamos nas redes, para comparar de forma justa.

Medimos desempenho com RMSE e MAE, além de calcular as discrepâncias entre o real e o previsto, repetindo a mesma análise feita para o NEWAVE.

O RMSE pesa mais os grandes erros, o MAE dá a média dos erros absolutos, então olhar os dois ajuda a entender o comportamento do modelo. Quando muda a escala (por exemplo, com agregações), também reportamos uma versão relativa (nRMSE) para comparar janelas e condições diferentes. Para saber onde está o ganho, fazemos ablation: testamos LSTM sozinha, Informer sozinho, CNN e depois LSTM, CNN e depois Informer, o ensemble CNN com (LSTM + Informer) e o XGBoost como controle.<sup>34</sup>

## 4.2 Apresentação de Resultados do NEWAVE

Os dados coletados no site oficial do CCEE foram dispostos em uma tabela no Google Planilhas. Como as previsões começavam em abril de 2020, os dados foram coletados a partir dessa data. Eles foram dispostos em uma tabela de modo que para o primeiro deck teríamos todas as 60 previsões e conforme elas fosse se aproximando de primeiro de janeiro de 2025, o número total de meses previstos considerados na análise iria diminuindo, formando uma espécie de pirâmide invertida, por fim a tabela ficaria com o mesmo formato da tabela 1

Previsões	Previsto ABR/2020	Previsto MAI/2020	...	Previsto DEZ/2024	Real ONS
04/2020	5040				4370
05/2020	6545	6544			6094
...	...	...	...	...	...
12/2024	7241	7373	...	9534	11453
01/2025					6780

Tabela 1: Exemplo da Disposição de Dados Para Análise do NEWAVE

Infelizmente a organização e disposição dos dados de cada deck é muito precária. A informação fica presente dentro de um arquivo específico chamado sistema.dat que relata a geração prevista para cada sistema do SIN. Após a extração de todos os valores de todas as previsões, exportamos a tabela com os dados para um csv e utilizamos Python para calcular métricas mais verbosas, como MAE, RMSE, Bias, Desvio Padrão, mínimo, máximo e quartis.

Como possuímos várias previsões para uma mesma data, geramos ainda o cálculo de diferença intra-previsão, ou seja, dada uma mesma data, para todas as previsões que possuíamos para aquela data, qual seria o erro médio. Desse modo, é possível ter a dispersão interna dos decks, entendendo se o modelo gera previsões consistentes (baixa dispersão) ou conflitantes (alta dispersão).

Com base nas métricas apresentadas pela tabela 2, observa-se que o algoritmo NEWAVE apresenta um alto grau de variabilidade e tendência de subestimar as medições em quase 10% (utilizando a média como parâmetro). O Min e Max demonstram

<sup>34</sup> Ahmadi2020\_TreeBased .

Média do Desvio Padrão Entre Decks	764,18
Média das Previsões	9167,95
Média dos Valores Reais	9091.04
Média do Erro Global	-806,47
Min Erro Global	-3383,32
Max Erro Global	2636,56
Média do Erro Entre Previsões	848,6
Correlação Desvio Padrão e MAE	62,82%
RMSE Médio	1521,86
MAE Médio	1351,44
Média do Desvio Padrão do Erro Global	1215,72
Bias	-806,474

Tabela 2: Métricas Calculadas Para Geração Eólica do NEWAVE

a variabilidade presente no algoritmo, os próprios decks variam em quase 800MWmed entre si, enquanto o erro dessas previsões ultrapassa esse valor.

Interessante notar como a diferença da média das previsões com a média dos valores reais é baixa, cerca de 100MWmed, o que suporta que as previsões, em média, podem corresponder com o mundo real, contudo, ao olha-las de modo mais individualizado, percebemos grandes erros e inconsistências. Isso fica ainda mais claro quando comparamos um deck específico com o real gerado. Traçando um gráfico da geração em função do tempo para um deck específico e o real obtemos os seguintes resultados:

### Previsto 2024 vs Real




Figura 5: Previsto pelo Deck 2024 vs Real

A figura 5 demonstra que mesmo em horizonte curto, apenas um ano de previsão à frente, o algoritmo subestima drasticamente o que de fato ocorreu. Isso pode se dar



em partes pelo viés que ele carrega, afinal, ano após ano batemos recorde de geração de energia eólica, justamente por se tratar de uma tecnologia em ascensão e crescente recente.

Parando para prestar mais atenção apenas nas diferenças entre o deck de 2024 e o que de fato ocorreu ao longo do ano até 2025, reparamos como os erros podem bater máximas gigantescas em certos momentos, chegando à quase um terço da média.

### Diferença Real e Previsto 2024




Figura 6: Diferença entre Real e Previsto

Parando para considerar outros horizontes de tempo ainda podemos desenvolver descobertas interessantes sobre as dificuldades e deficiências apresentadas pelo NEWAVE.

Como mencionado acima, a desvalorização das previsões pode se dar devido à grande flutuação de mercado presente no desenvolvimento e produção de tecnologias de geração eólica. Um bom modelo de previsão de geração de energia a partir do vento não deve ser capaz de prever velocidades do vento, mas também qual seria a tendência de crescimento do mercado e de que modo isso afetaria o próximo ano comercial. A figura 7 demonstra com clareza essa hipótese. Conforme os anos vão avançando, ocorre um aumento significativo na dispersão de previsões de decks diferentes para uma mesma data, ou seja, aumento significativo de incerteza adicionado pelo algoritmo.




Figura 7: Diferença Média Entre Previsões

Vale ressaltar que esse pico também corrobora para essa narrativa o fato de que datas mais recentes também possuem mais previsões. Apenas um deck previu valores para maio de 2020, o deck de abril de 2020, contudo, todos os decks a partir de janeiro de 2021 previram a geração para janeiro de 2025. Mesmo assim é possível notar um crescimento na incerteza ao decorrer dos anos.

Também é possível ver um certo delay até que o algoritmo entenda o aumento do próprio mercado eólico, é possível notar em decks mais recentes, como na figura 8 como o modelo já passa a aumentar a geração de um ano para o outro, superestimando inclusive os próprios valores reais.

## Real vs Previsto 2023




Figura 8: Real contra Previsto Deck Newave 2023

Uma última análise interessante a ser retirada desse estudo fica presente nas duas imagens abaixo. Afinal, percebe-se como esses decks possuem força e regulação quando vistos em média, mas se tornam muito imprecisos e incapazes de prever a real geração quando olhados a sós.

Fica desse modo, portanto, provado categoricamente a ineficácia e incapacidade desse modelo em prever o mundo real. Mas além disso é possível perceber que a previsão de geração de energia eólica, vai muito além de dados como apenas a velocidade do vento, é resultado de uma gama variáveis que contribuem para uma realidade única, temperatura, pressão atmosférica, umidade, dados socioeconômicos como PIB, IDH, todos eles podem influenciar a quantidade de energia eólica a ser gerada, e precisamos manter todos esses fatores em mente para gerar um bom modelo.

O modelo NEWAVE demonstra ser fundamentalmente inadequado para a previsão de geração eólica devido a graves problemas processuais, incluindo dados de entrada e saída desorganizados e não padronizados que impedem a automação e dificultam a análise. Suas previsões carecem de confiabilidade e precisão, exigindo o uso de médias em horizontes longos para encontrar alguma semelhança com os dados reais, o que demonstra sua inconsistência. Dado que modelos mais modernos, como XGBoost, já se provaram eficazes em previsões energéticas sazonais, a ineficiência do NEWAVE, evidencia a necessidade urgente de programas especializados para o crescente setor eólico.

Este estudo demonstrou de forma quantitativa as limitações do NEWAVE na previsão de geração eólica, evidenciando viés sistemático, elevada dispersão interna e erros médios superiores a 1 GW, fornecendo subsídios claros para calibrar o modelo, aprimorar a assimilação de dados meteorológicos e explorar metodologias complementares que aumentem a confiabilidade das previsões no planejamento energético.




Figura 9: Média das Previsões contra Real




Figura 10: Deck de FEV/2021 contra Real

### 4.3 Limitações Previstas

Embora a proposta integre avanços recentes em modelagem sequencial e atencional, algumas limitações precisam ser explicitadas para interpretar corretamente os resultados. Em primeiro lugar, o horizonte de previsão de 5 anos e a granularidade das séries condicionam o regime de erro: horizontes muito extensos tendem a amplificar incertezas meteorológicas e estruturais, ao passo que agregações temporalmente muito pouco definidas podem suavizar indevidamente a variabilidade eólica relevante à operação. Em segundo lugar, o conjunto de atributos efetivamente disponível, em particular, a qualidade e a profundidade das variáveis meteorológicas exógenas, define o teto de desempenho do sistema: ausências ou lags excessivos em previsores climáticos deterioram a capacidade do modelo de antecipar rampas e quebras de regime. Em terceiro lugar, a função de perda adotada durante o treinamento pode privilegiar diferentes aspectos do erro. Por exemplo, MSE penaliza fortemente grandes desvios. Devendo, desse modo, ser alinhada ao critério de decisão operacional que orienta o estudo.

Há, ainda, considerações computacionais e de reprodutibilidade. Apesar do *Informer* ser mais eficiente que *Transformers* densos, seu treinamento para horizontes longos continua mais custoso que alternativas puramente recorrentes. Por isso, o desenho final equilibra capacidade e custo para manter a proposta auditável e reproduzível com recursos acadêmicos.

Finalmente, cumpre notar que o ensemble aqui proposto foi deliberadamente contido, dois ramos neurais mais um baseline tree-based – para maximizar transparência e diagnosticabilidade. A intenção é que as análises de ablação revelem onde o ganho ocorre, ou seja, ao isolar diferentes partes do modelo, podemos entender melhor sua contribuição para o todo. Atributos convolucionais, memória recorrente ou dependências globais podem demonstrar se é necessário, simplificar a arquitetura sem perdas materiais de desempenho. Essas escolhas, ao mesmo tempo em que preservam o rigor experimental, mantêm a proposta dentro de um escopo factível para aplicação real, em linha com a motivação prática do trabalho.

Visando ainda as limitações físicas de hardware, o estudo fica limitado pela falta de análise de robustez do modelo, ou falta de definição/variação de definição dos dados. Para esse estudo os modelos serão treinados considerando apenas os dados meteorológicos diários, afinal, qualquer janela além disso seria irreal para um computador doméstico com armazenamento limitado processar. Buscando dados horários o conjunto de dados beirava os terabytes.

## 5 Cronograma

O cronograma foi desenvolvido visando a melhor distribuição de tarefas, considerando um quadro de 1 ano, ou seja, dois períodos. Cada janela de tempo faz jus à 4 dias.

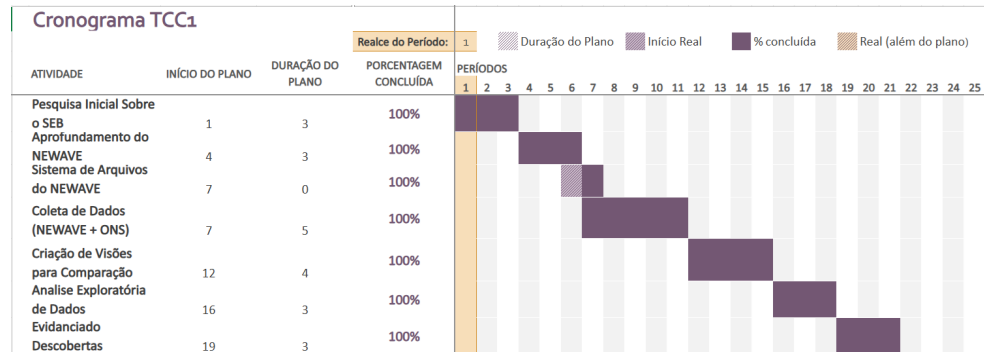


Figura 11: Parte 1 Cronograma




Figura 12: Parte 2 Cronograma

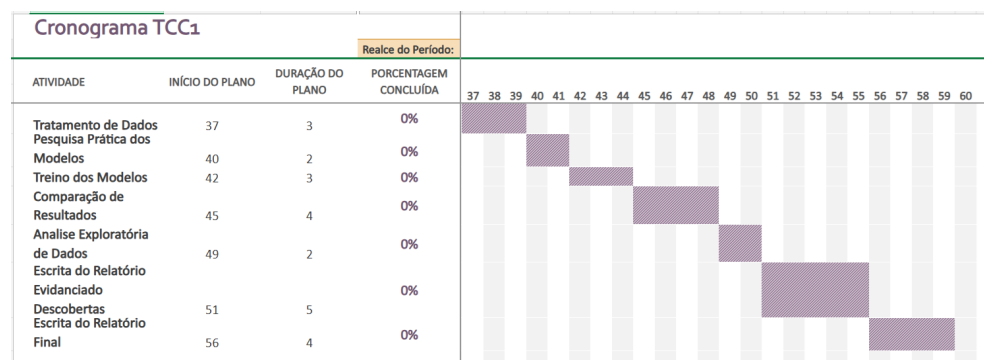


Figura 13: Parte 3 Cronograma

## 6 Bibliografia

### Referências

AGÊNCIA NACIONAL DE ENERGIA ELÉTRICA (ANEEL). **Nota Técnica nº 068/2022-SRG/ANEEL: critérios e procedimentos para aprovação do Custo Variável Unitário (CVU) de usinas termelétricas**. [S. l.], 9 jun. 2022. Define que o CVU de UTE engloba combustível (maior parcela) + O&M variável, em R\$/MWh. Disponível em: [https://antigo.aneel.gov.br/web/guest/consultas-publicas?\\_participacaopublica\\_WAR\\_participacaopublicaportlet\\_ideDocumento=47333&\\_participacaopublica\\_WAR\\_participacaopublicaportlet\\_jspPage=%2Fhtml%2Fpp%2Fvisualizar.jsp&\\_participacaopublica\\_WAR\\_participacaopublicaportlet\\_tipoFaseReuniao=fase&p\\_p\\_mode=view](https://antigo.aneel.gov.br/web/guest/consultas-publicas?_participacaopublica_WAR_participacaopublicaportlet_ideDocumento=47333&_participacaopublica_WAR_participacaopublicaportlet_jspPage=%2Fhtml%2Fpp%2Fvisualizar.jsp&_participacaopublica_WAR_participacaopublicaportlet_tipoFaseReuniao=fase&p_p_mode=view). Acesso em: 4 nov. 2025.

AHMADI, Amirhossein *et al.* Long-Term Wind Power Forecasting Using Tree-Based Learning Algorithms. **IEEE Access**, 2020. DOI: 10.1109/ACCESS.2020.3017442.

BARBOUNIS, Thanasis G. *et al.* Long-Term Wind Speed and Power Forecasting Using Local Recurrent Neural Network Models. **IEEE Transactions on Energy Conversion**, v. 21, n. 1, p. 273–, 2006.

BELOTTI, Jônatas Trabuco. **Previsão de vazões afluentes utilizando redes neurais artificiais e ensembles**. 2019. 139 f. Dissertação (Mestrado em Ciência da Computação) – Universidade Tecnológica Federal do Paraná (UTFPR), Ponta Grossa. Disponível em: <https://repositorio.utfpr.edu.br/jspui/handle/1/4037>. Acesso em: 15 fev. 2025.

BRANDÃO, Simone Quaresma *et al.* Hydropower Enhancing the Future of Variable Renewable Energy Integration: A Regional Analysis of Capacity Availability in Brazil. **Energies**, v. 17, n. 13, 3339, 2024. DOI: 10.3390/en17133339. Disponível em: <https://www.mdpi.com/1996-1073/17/13/3339>. Acesso em: 4 nov. 2025.

BRASIL. EMPRESA DE PESQUISA ENERGÉTICA (EPE). **Matriz elétrica — Brasil**. [Imagem]. Disponível em: <https://www.epe.gov.br/sites-pt/abcdenergia/PublishingImages/Matriz%20energ%C3%A9tica/05-%20elettrica%20brasil.png>. Acesso em: 4 nov. 2025.

BRASIL. OPERADOR NACIONAL DO SISTEMA ELÉTRICO (ONS). **O Sistema Interligado Nacional**. Disponível em: <https://www.ons.org.br/paginas/sobre-o-sin/o-que-e-o-sin>. Acesso em: 4 nov. 2025.

CASTRO, Nivalde de; MATSUMURA, Emilio Hiroshi. **A Importância do Planejamento do Setor Elétrico Brasileiro**. [S. l.: s. n.], 2021. Artigo institucional sobre planejamento, PNE/PDE e prazos de maturação. Disponível em: [https://www.gesel.ie.ufrj.br/app/webroot/files/publications/03\\_castro\\_2021\\_03\\_08.pdf](https://www.gesel.ie.ufrj.br/app/webroot/files/publications/03_castro_2021_03_08.pdf). Acesso em: 4 nov. 2025.

CCEE. Disponível em: <https://www.ccee.org.br/pt/web/guest/acervo-ccee>. Acesso em: 11 abr. 2025.

CENTRO DE PESQUISAS DE ENERGIA ELÉTRICA (CEPEL). **Manual do Usuário NEWAVE**. Rio de Janeiro, 2023. 373 p. Disponível em: <https://www.cepel.br/wp-content/uploads/2024/10/ManualUsuario-2.pdf>. Acesso em: 16 abr. 2025.

ELSHEWEY, Ahmed M.; JAMJOOM, Mona M.; ALKHAMMASH, Eman H. An enhanced CNN with ResNet50 and LSTM deep learning forecasting model for climate change decision making. **Scientific Reports**, v. 15, 14372, 2025. DOI: 10.1038/s41598-025-97401-9.

EMPRESA DE PESQUISA ENERGÉTICA (EPE). **Plano Nacional de Energia 2030 — Geração Hidrelétrica**. Rio de Janeiro, 2007. Disponível em: <https://www.epe.gov.br/sites-pt/publicacoes-dados-abertos/publicacoes/PublicacoesArquivos/publicacao-165/topico-173/PNE%202030%20-%20Gera%C3%A7%C3%A3o%20Hidrel%C3%A9trica.pdf>. Acesso em: 4 nov. 2025.

EWEES, Ahmed A. *et al.* HBO-LSTM: Optimized long short term memory with heap-based optimizer for wind power forecasting. **Energy Conversion and Management**, v. 268, 116022, 2022. DOI: 10.1016/j.enconman.2022.116022.

CONHEÇA as instituições do setor elétrico brasileiro e as competências de cada uma. Ministério de Minas e Energia. 2025. Disponível em: <https://www.gov.br/mme/pt-br/assuntos/noticias/conheca-as-instituicoes-do-setor-eletrico-brasileiro-e-as-competencias-de-cada-uma>. Acesso em: 4 nov. 2025.

NETO, Arthur Kolling *et al.* Advancing Medium-Range Streamflow Forecasting for Large Hydropower Reservoirs in Brazil by Means of Continental-Scale Hydrological Modeling. **Water**, v. 15, n. 9, 1693, 2023. DOI: 10.3390/w15091693. Disponível em: <https://www.mdpi.com/2073-4441/15/9/1693>. Acesso em: 4 nov. 2025.

OLIVEIRA, Francisco José Arteiro de (ed.). **O Planejamento da Operação Energética no Sistema Interligado Nacional: conceitos, modelagem matemática, previsão de geração e carga**. São Paulo: Artliber Editora Ltda., 2020. Operador Nacional do Sistema Elétrico (ONS). ISBN 978-65-86443-02-8. Disponível em: <https://www.ons.org.br/AcervoDigitalDocumentosEPublicacoes/0%20Planejamento%20da%20Operacao%20Energ%C3%A9tica%20no%20Sistema%20Interligado%20Nacional%20conceitos,%20modelagem%20matem%C3%A9tica,%20previs%C3%A3o%20de%20gera%C3%A7%C3%A3o%20e%20carga.pdf>. Acesso em: 4 nov. 2025.

OPERADOR NACIONAL DO SISTEMA ELÉTRICO (ONS). **Submódulo 18.8: modelos computacionais**. Rio de Janeiro, 2002. 26 p. Disponível em: [https://www.ons.org.br/%2FProcedimentosDeRede%2FM%C3%B3dulo%2018%2FSubm%C3%B3dulo%2018.2%2FSubm%C3%B3dulo%2018.2\\_%20Rev\\_0.0.pdf](https://www.ons.org.br/%2FProcedimentosDeRede%2FM%C3%B3dulo%2018%2FSubm%C3%B3dulo%2018.2%2FSubm%C3%B3dulo%2018.2_%20Rev_0.0.pdf). Acesso em: 16 abr. 2025.



PRIORIZAÇÃO de temas para os próximos ciclos. [S. l.], 2022. 31 p. Disponível em: [https://antigo.mme.gov.br/c/document\\_library/get\\_file?groupId=36070&uuid=0308ec8c-5114-76af-88e7-79fe68672540](https://antigo.mme.gov.br/c/document_library/get_file?groupId=36070&uuid=0308ec8c-5114-76af-88e7-79fe68672540). Acesso em: 4 nov. 2025.

MAPA dos terminais/instalações portuárias do litoral paulista. SOPESP. 2019. Disponível em: <https://soresp.com.br/wp-content/uploads/2019/10/mapa.png>. Acesso em: 4 nov. 2025.

THE changing role of hydropower: Challenges and opportunities. Abu Dhabi, fev. 2023. ISBN 978-92-9260-522-3. Disponível em: <https://www.irena.org/Publications/2023/Feb/The-changing-role-of-hydropower-Challenges-and-opportunities>. Acesso em: 4 nov. 2025.

WANG, Kun *et al.* Long-Term Power Load Forecasting Using LSTM-Informer with Ensemble Learning. **Electronics**, v. 12, 2175, 2023. DOI: 10.3390/electronics12102175.

WIND/PV Integration Studies — Recommended Practices 16, Edition 3. [S. l.], dez. 2024. Recommended Practices for integrating wind and solar PV in power systems. Disponível em: <https://iea-pvps.org/wp-content/uploads/2025/01/IEA-PVPS-T14-28-2024-REPORT-Wind-PV-Integration.pdf>. Acesso em: 4 nov. 2025.